UP
Universidad
de Palermo

Diplomatura en Inteligencia Artificial 2025

Prof. Carlos A. Giménez

Módulo 2 – Machine Learning

Bloque Temático 2

- Introducción Visual a ML.
- Entropía.
- Log Loss.
- Impureza de GINI.
- Ej. Árbol de Clasificación.
- Árbol de Regresión.
- Ej. Árbol de Regresión.

A visual introduction to machine learning

Entropía

Concepto

Claude Elwood Shannon (30 de abril de 1916 - 24 de febrero de 2001) fue un matemático, ingeniero eléctrico y criptógrafo estadounidense recordado como «el padre de la teoría de la información».[1][2]

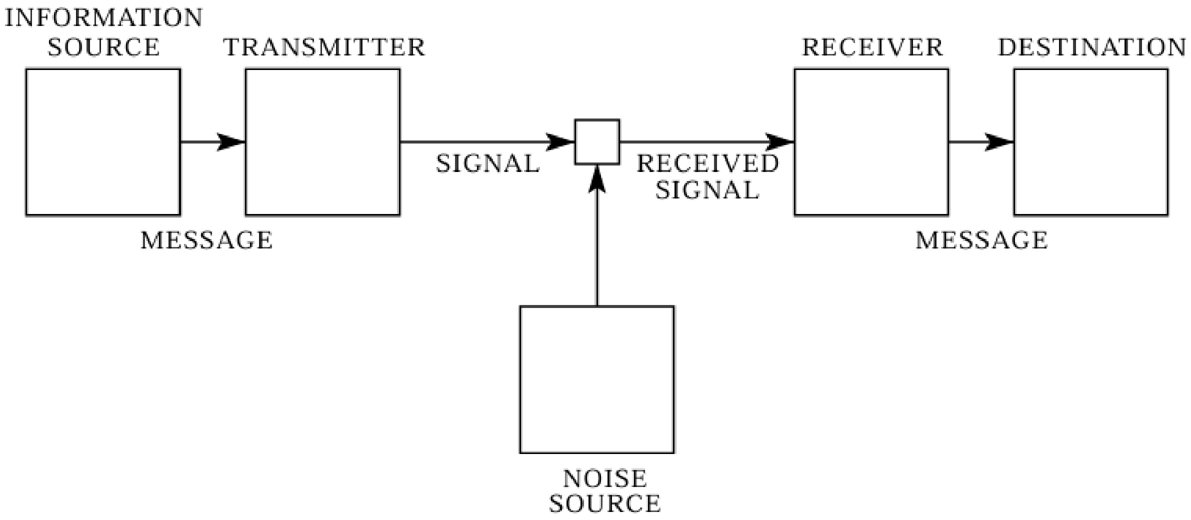

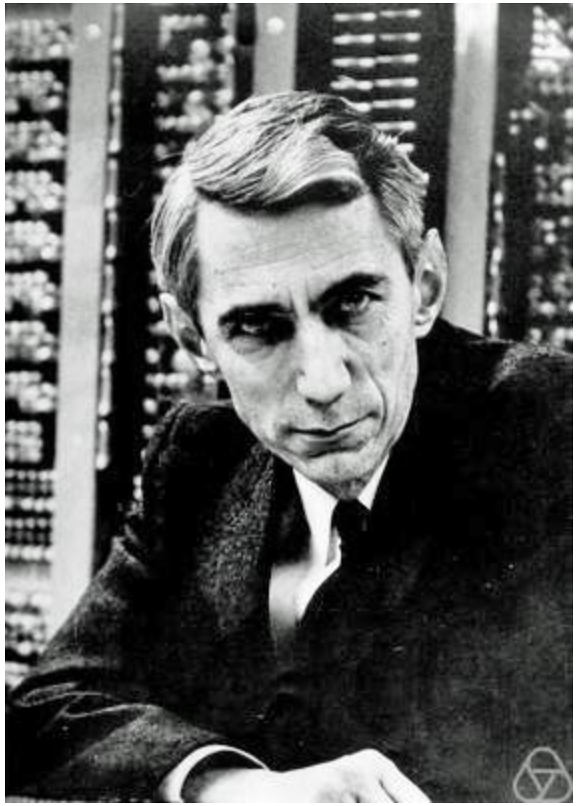

Entropía

Clasificación

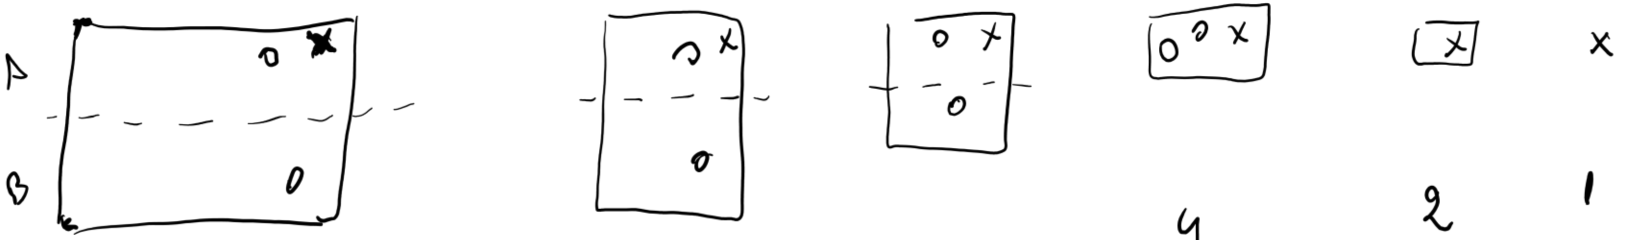

32 — 1 bit

16 — 2 bit

8 — 3 bit

4 — 4 bit

2 — 5 bit

1

$32 \to$ ¿bit?

$\log_2 32 = 5$

$2^5 = 32$

$\log_2\left(\frac{32}{2}\right) = 4$

$\log_2\left(\frac{32}{4}\right) = \dots$

$\log_2\left(\frac{1}{p_i}\right)$

$\frac{2}{32} = p_2$

$\sum p_i \log_2\left(\frac{1}{p_i}\right)$

$$\boxed{E = -\sum p_i \log_2(p_i)}$$

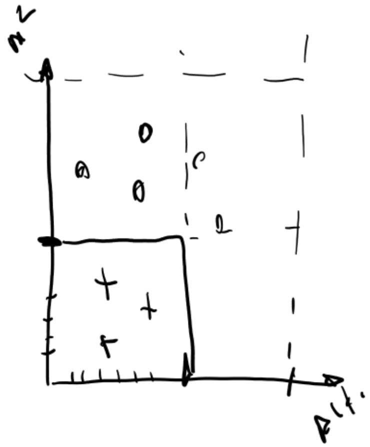

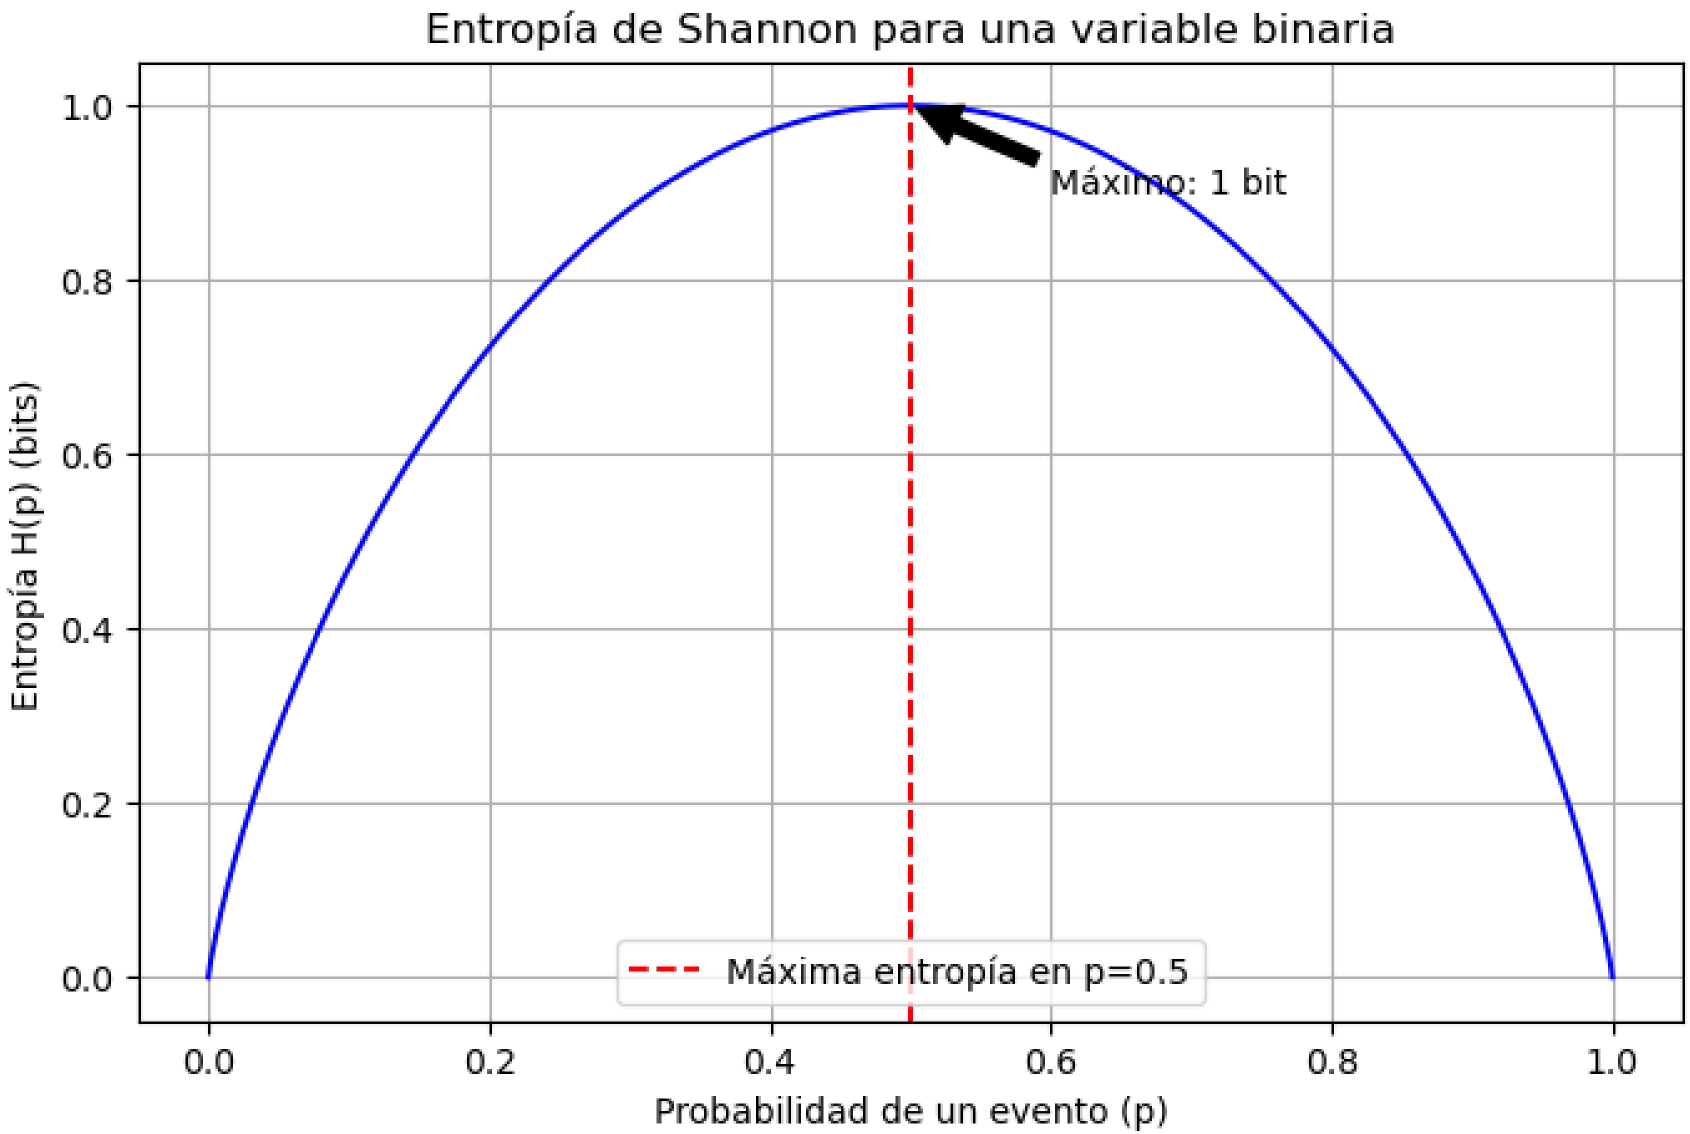

Entropía de Shannon para una variable binaria
Máximo: 1 bit
Máxima entropía en p=0.5
Entropía H(p) (bits)
Probabilidad de un evento (p)
0.0
0.2
0.4
0.6
0.8
1.0

Impureza de GINI

Clasificación

$$G = \sum_{i=1}^{k} p_i * (1 - p_i)$$

0,38 UR
0,42 AR

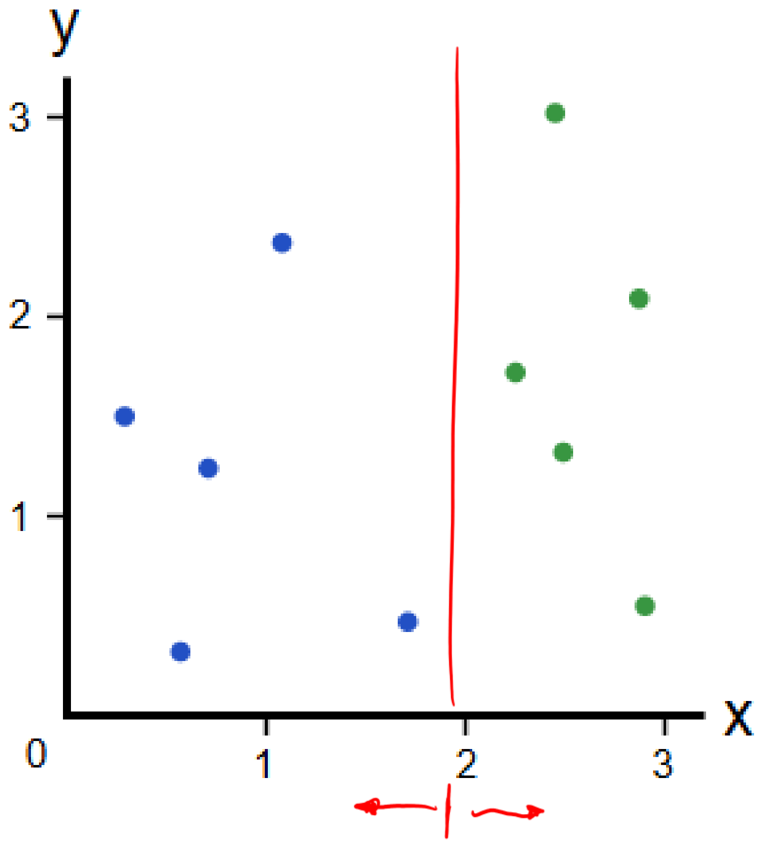

Azul Verde

$$G_L = 1 \cdot (1-1) + 0 \cdot (1-0) = 0$$

$$G_R = 0 \cdot (1-0) + 1 \cdot (1-1) = 0$$

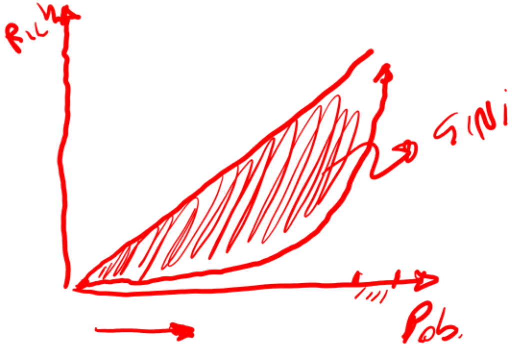

Impureza de GINI

Clasificación

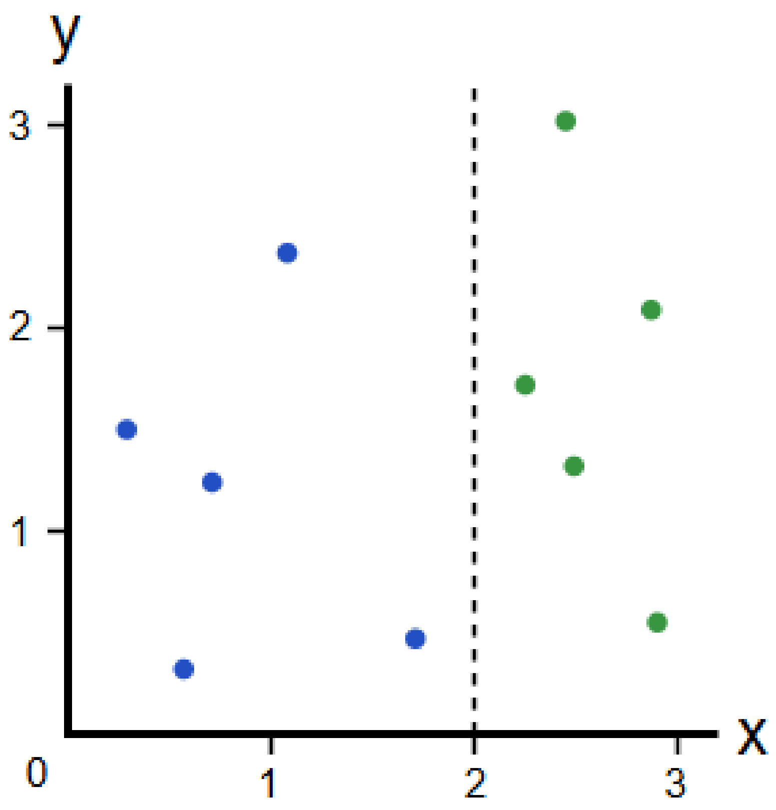

$$G_L \cdot \frac{5}{10} + G_R \cdot \frac{5}{10} = 0$$

Impureza de GINI

Clasificación

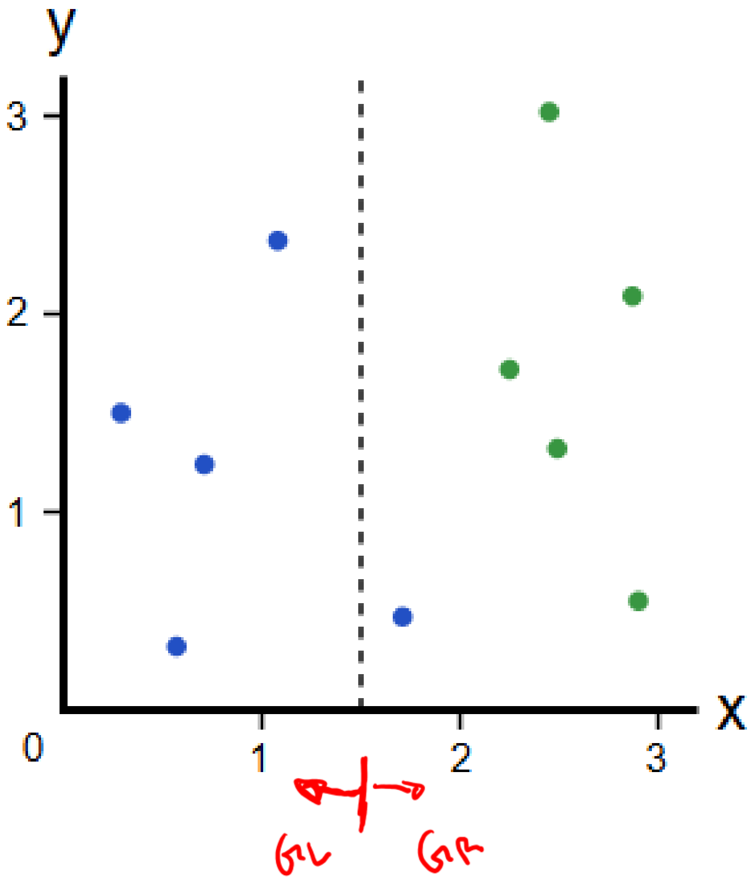

$$G_L = 1\cdot(1-1) + 0(1-0) = 0$$

$$G_R = \frac{1}{6}\left(1-\frac{1}{6}\right) + \frac{5}{6}\left(1-\frac{5}{6}\right) = 0{,}28$$

$$\cancel{G_L \times \frac{4}{10}} + G_R \times \frac{6}{10} = 0{,}28 \cdot \frac{6}{10} = \boxed{0{,}168}$$

$$G_G = 1 - 0{,}168$$

Log Loss

Clasificación

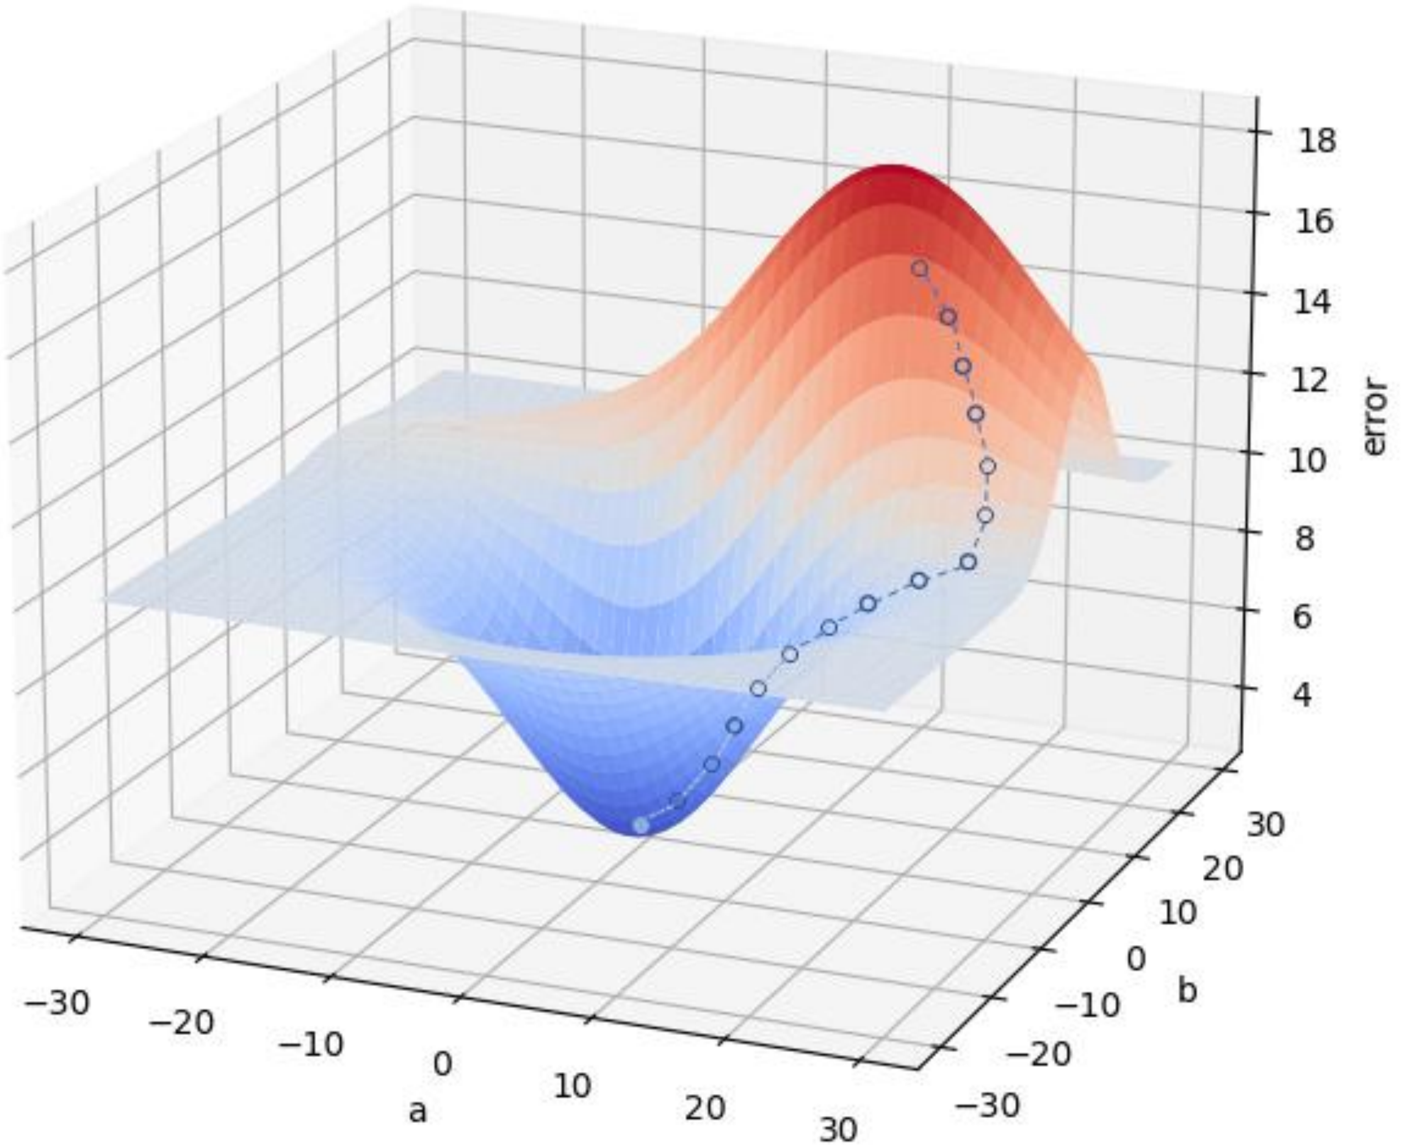

Log Loss
Clasificación

$$f_{w,b}(x) = \frac{1}{1 + e^{-(w+bx)}}$$

Función de pérdida:

$$L(w, b) = -y \log\left(f_{w,b}(x)\right) - (1 - y)\log(1 - f_{\mathrm{w,b}}(\mathrm{x}))$$

Función de costo:

$$\mathrm{J}(w, b) = \frac{1}{m}\sum_{i=1}^{m} L(w, b)$$

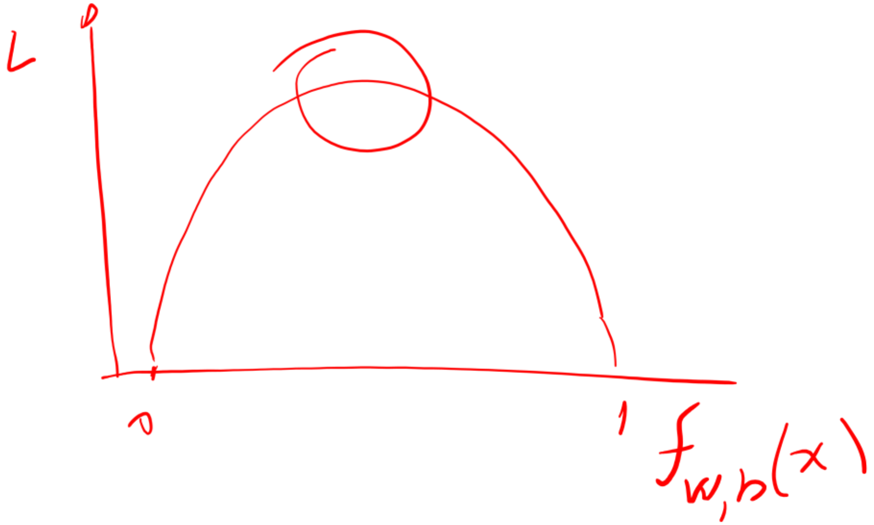

Log Loss

Clasificación

Función de pérdida:

$$f_{w,b}(x) = \frac{1}{1 + e^{-(w+bx)}}$$

$$L(w,b) = -y\log\left(f_{w,b}(x)\right) - (1-y)\log(1 - f_{\mathrm{w,b}}(\mathrm{x}))$$

Función de costo:

$$J(w,b) = \frac{1}{m}\sum_{i=1}^{m} L(w,b)$$

Debemos encontrar w, b que minimice J(w,b):

Aplicamos gradiente:

$$\frac{\partial}{\partial b}J(w,b) = \frac{1}{m}\sum_{i=1}^{m}(f_{w,b}(x_i) - y_i)\,x_i$$

$$\frac{\partial}{\partial w}J(w,b) = \frac{1}{m}\sum_{i=1}^{m}(f_{w,b}(x_i) - y_i)$$

60%
Train
Testing
Validación
Testing
Validación
60%
Train
60%
Testing
Train
Validación
CROSS VALIDATION

Arboles de Regresión

Regresiones

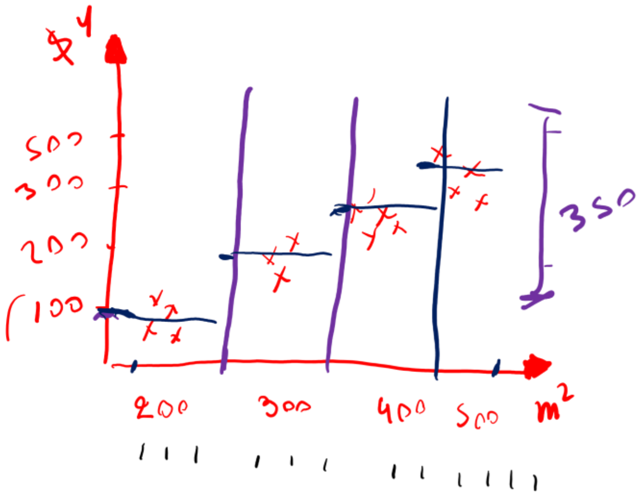

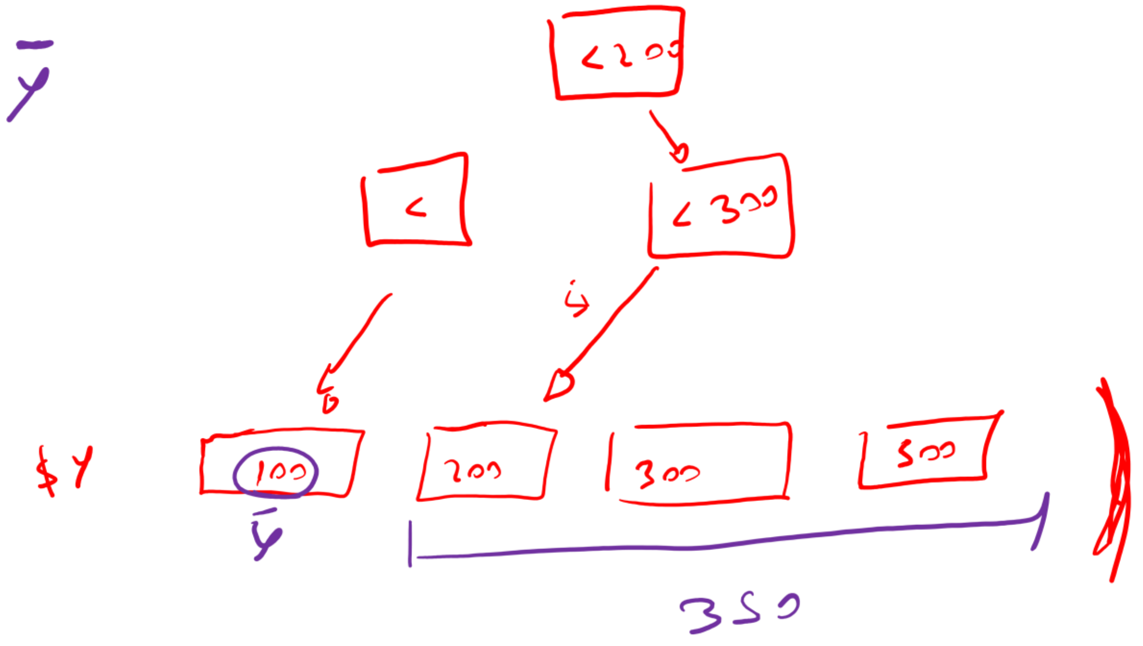

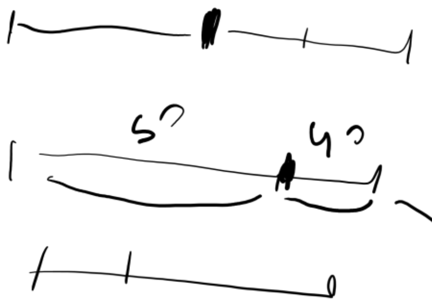

MAE b

$$\frac{50}{90} \cdot MAE_1 + \frac{40}{90} MAE_2 = MAE_{c_1}$$

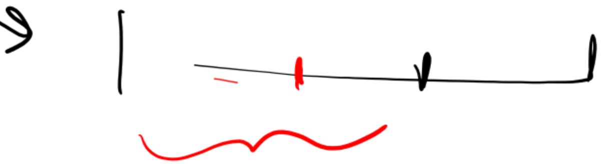

Arboles de Regresión

Regresiones

$$MAE = \frac{1}{N}\sum_{i=1}^{N} |y_i - \hat{y}|$$

Arboles de Regresión

Regresiones

$$MAE = \frac{1}{N}\sum_{i=1}^{N} |y_i - \hat{y}|$$

$$MSE = \frac{1}{N}\sum_{i=1}^{N} (y_i - \hat{y})^2$$

Arboles de Regresión

Regresiones

$$MAE = \frac{1}{N}\sum_{i=1}^{N} |y_i - \hat{y}|$$

$$MSE = \frac{1}{N}\sum_{i=1}^{N} (y_i - \hat{y})^2$$

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N} (y_i - \hat{y})^2}$$

Arboles de Regresión

Regresiones

$$MAE = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}|$$

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y})^2$$

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y})^2}$$

$$R^2 = 1 - \frac{\sum(y_i - \hat{y})^2}{\sum(y_i - \bar{y})^2}$$

Arboles de Regresión

Regresiones

$$MAE = \frac{1}{N}\sum_{i=1}^{N} |y_i - \hat{y}|$$

$$MSE = \frac{1}{N}\sum_{i=1}^{N} (y_i - \hat{y})^2$$

$$RMSE = \sqrt{MSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N} (y_i - \hat{y})^2}$$

$$R^2 = 1 - \frac{\sum (y_i - \hat{y})^2}{\sum (y_i - \bar{y})^2}$$

$$R_{adj}^2 = 1 - \left[\frac{(1 - R^2)(n-1)}{n-k-1}\right]$$