




TIME-SERIES FORECASTING



POR: SEBASTIAN SARASTI

RESUMEN DE CONTENIDOS



INTRODUCCIÓN/HISTORIA

MODELOS PREVIOS

MODELOS FUNDACIONALES

TIMESFM

DEMO

TIME-SERIES



INTRODUCCIÓN

TIME-SERIES ESTÁN EN TODOS LADOS



TIME-SERIES ESTÁN EN TODOS LADOS





TIME-SERIES ESTÁN EN TODOS LADOS



“

QUÉ TIENEN EN
COMÚN LAS
IMÁGENES?






TIME-SERIES

FUNDAMENTOS MATEMÁTICOS

TIME-SERIES ES UN PROBLEMA DE REGRESIÓN CON RESTRICCIONES

FUNDAMENTO

Var A, Var B, Var C




Number

TIME-SERIES BUSCA APRENDER MEDIANTE SECUENCIAS HISTÓRICAS

ENTRENAMIENTO

Val X-3, Val X-2, Val X-1


Val Y-3, Val Y-2, Val Y-1



Val X

LAS VALIDACIONES HOLD-OUT CARECEN DE SENTIDO EN LAS TIME-SERIES

RESTRICCIÓN



1. Train each split with optimal parameters
2. Average each split's test error

MODELO DE TIME-SERIES EN POCAS PALABRAS

$$Y_T = F(Y_{T-1}, Y_{T-2}, \dots, Y_{T-N}, X^1_{T-1}, X^2_{T-2})$$

Y_T : Next value to predict

F : Model created


Y_{T-N} : Previous values at time-step n

X^N_{T-N} : Correlated variables at previous time-step n



CUÁL ES EL SIGUIENTE
VALOR?

0, 0, 1, 1, 2, 3, 5, 8



???

TIME-SERIES EN LA VIDA REAL

A que activo/item pertenece esta serie de tiempo?



TIME-SERIES



MODELOS SIMPLES

ESTÁNDARES DE LA INDUSTRIA

ARIMA

- Series de tiempo estacionarias
- SARIMAX para variables exógenas/seasonality

HOLT-WINTERS

- No variables exógenas
- Puede lidiar con series no estacionarias y seasonality directamente.

EL DEEP LEARNING VIVE ETAPAS

ETAPA 1

Redes simples (FFNN)

ETAPA 2

Redes más complejas

ETAPA 3

Modelos reusables

REQUERIMIENTOS PARA SER UN MODELO FUNCIONAL

CANTIDAD
DE DATOS

Entrenarse sobre
millones de datos


ARQUITECTURA

Ser un modelo de
millones de parámetros

KNOWLEDGE
ACQUISITION

Zero-shot o Few-shot
capabilities

ACASO EL LENGUAJE NO ES SIMILAR A
LAS SERIES DE TIEMPO?



Sebastián es hermoso y bello ...

0, 0, 1, 1, 2, 3, 5, 8, 13, 21,



TIME-SERIES



TRANSFORMADORES

Attention Is All You Need

Ashish Vaswani*
Google Brain
avaswani@google.com

Noam Shazeer*
Google Brain
noam@google.com

Niki Parmar*
Google Research
nikip@google.com


Jakob Uszkoreit*
Google Research
usz@google.com

Llion Jones*
Google Research
llion@google.com

Aidan N. Gomez* †
University of Toronto
aidan@cs.toronto.edu


Łukasz Kaiser*
Google Brain
lukaszkaizer@google.com

Illia Polosukhin* ‡
illia.polosukhin@gmail.com



TRANSFORMER

ENCODER




DECODER

LOS ENCODERS COMPRIMEN LA INFORMACIÓN

ENCODER

- Semantic embedding
- Positional embedding
- Attention block (self)




LOS DECODERS GENERAN INFORMACIÓN ÚTIL

DECODER

- Semantic embedding
- Positional embedding
- Attention block (mask and cross-attention)
- Autoregressive

LOS EMBEDDINGS SEMÁNTICOS SON
REPRESENTACIONES MEANINGFUL DE
CADA ELEMENTO



LOS EMBEDDINGS POSICIONALES AYUDAN A COMPRENDER EL ORDEN DE LOS ELEMENTOS

Sebastián ayudó a Pablo en España


Sujeto 1: Pablo

Predicado: Sebastián

Lugar: España



LOS BLOQUES DE SELF-ATTENTION PERMITEN CAPTURAR RELACIONES ENTRE LAS SECUENCIAS




GIF

TIME-SERIES



TIMESFM

TIMESFM ARCHITECTURE



PATCHING


0, 0, 1, 1, 2, 3, 5, 8, 13,

Patch 1


Patch 2

Patch 3

Patches continuos, no overlapping




RESNET EMBEDDING




Procesa el patche y evita gradient vanishing

TRANSFORMERS ACTUANDO AUTOREGRESIVAMENTE


Step 1



Step 2




Step 3



Cada nuevo input, requiere ejecutar el modelo


OBTENIENDO PREDICCIONES



El modelo predice patches y no números solos



“


QUICK DEMO





¡MUCHAS
GRACIAS!





LinkedIn